研究筆記

當太陽能發電急升急跌：預測區間改善了，為甚麼仍不夠可靠？

帶着這個問題閱讀

區間改善之後，在功率急變及輸入缺失時，是否已足夠可靠？

留意這幾點

- 把平均改善，與最困難合資格群組的覆蓋率分開比較。
- 一起閱讀覆蓋率、區間闊度、適當評分及預測可用率。
- 分清獨立站點、未來事件標籤，以及缺失資料足以支持哪些比較。

適合對象

對預測、不確定性與學生研究有興趣的讀者。

先備知識

百分比與預測區間；正文會解釋校準及覆蓋率。

證據與界線

審核使用五個確認站點的 2019–2020 公開觀測；所有可部署候選仍未通過絕對可靠性檢查，缺少當前功率的預測起點亦被排除。

發布：2026年9月9日　約 26 分鐘閱讀

文章網址：https://skckenneth.github.io/zh/writing/when-solar-power-changes-fast/

想像一位太陽能電站操作人員，正在一片雲層越過站點時查看最新預測。中央預測線開始移動，旁邊的陰影帶看起來提供了某種保障：這是一個 90% 預測區間。操作人員並不是要求模型預知一切，而是想知道，當發電量急升急跌、部分感測資料又暫時無法取得時，究竟可以對這個範圍有多大信心。

這是一個假想操作情境，不是本研究已測試的部署案例。但它正好指出研究的核心疑問：陰影帶旁邊的數字，描述的是我們最需要它的時刻，還是主要描述了資料中數量較多、情況較普通的時刻？如果最容易出問題的情境只佔少數，整體平均數可能不會主動提醒我們。

改善這條不確定性帶，有兩種不同的意思。一種是令它比現有方法表現更好；另一種是令它可靠到足以滿足一個明確要求。方法完全可能做到前者，卻仍然做不到後者。我們的太陽能預測結果就提供了一個具體例子：校準令五個確認站點全部改善，但最弱的可評估群

組，距離原定覆蓋目標仍然很遠。

本文以這個區別解說我們獲 ADMA 2026 接納的短論文。它是一項使用公開能源數據的實證研究，不是一條保證所有條件覆蓋率的新定理。專案簡介整理研究與作者資料；學生研究工作室則記錄這項工作的研究指導背景。下面先看結果，再逐步拆解模型、分母、比較方法，以及那些沒有被改善數字解決的問題。

這個太陽能實驗發現了甚麼

研究包括五個站點、四個按時間排列的資料折，以及兩個預測期，合共 **40 個站點—時間折—預測期評估組合**。表現最一致的校準候選 Descriptor CQR，令平均站點最差群組欠覆蓋，在 **15 分鐘減少 0.110，在 60 分鐘減少 0.080**。這些是覆蓋短缺的絕對變化，等於 11.0 及 8.0 個百分點，不是相對百分比改善。

可是，相對於標稱 0.90 覆蓋率，仍然存在的最差欠覆蓋是 **0.430 及 0.363**。對應群組的實測覆蓋率只有 **0.470 及 0.537**。它們是最困難而又有足夠樣本的群組，不是全體平均；無論哪一個數字，都不能被包裝成「標稱 90% 的區間，在實際上已達到 90%」。

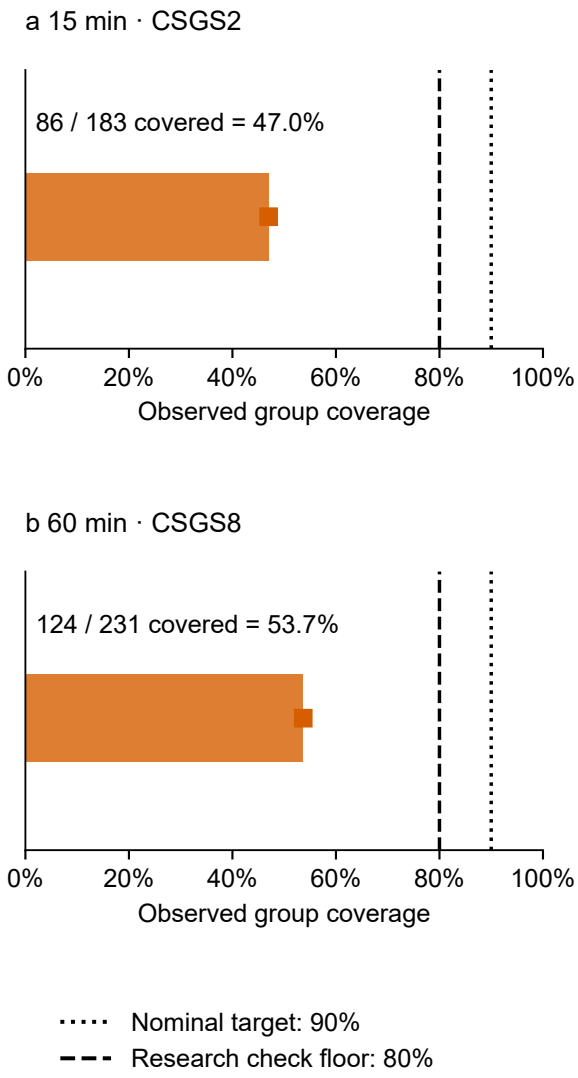


圖 1・Descriptor CQR 仍未達到可靠性檢查底線。15 分鐘下，CSGS2 在 2020 年第一季、天氣特徵移除且有 ramp 的群組，183 個目標只覆蓋 86 個；60 分鐘下，CSGS8 對應群組的 231 個目標覆蓋 124 個。點線 90% 是標稱目標；虛線 80% 是本研究刻意採用的寬鬆檢查底線，不是業界標準。這些樣本是所選群組內的觀測，不是獨立站點重複。

即使還不知道模型如何運作，這個落差已經清楚可見。把方法推向正確方向，不代表它已經到達目的地。要理解為甚麼會出現這種結果，我們需要先弄清楚覆蓋率的意思，再看看哪些觀測會被納入計算，哪些觀測在計算之前已被排除。否則，同一個「可靠」字眼，可能在不同段落指向完全不同的事情。

90% 究竟描述了甚麼？

在發出預測時，區間提供一個下界和一個上界。等未來功率實際量度出來，我們便可以檢查：這次的真值有沒有落在當時給出的範圍內？覆蓋率就是所有受評估目標中，落在各自區間內的比例。它描述的是重複使用一套預測程序的表現，不代表每一個特定區間都已被另外驗證，確定具有相同的個別機率。

即使整體覆蓋率估計得很準，仍然有第二個問題：是在甚麼條件之下的覆蓋率？以下只是一個算術示例，不是額外實驗結果。假設 90% 的預測發生在普通情況，覆蓋率達 95%；另外 10% 屬於困難事件，覆蓋率只有 45%。把兩部分混在一起，整體覆蓋率剛好等於 90%。漂亮的總數與少數重要情境下的低可靠性，完全可以同時存在。

因此，本研究在每個評估群組內分開三個數量。以 A_g 表示嘗試作出預測的次數，以 I_g 表示成功發出區間的次數，以 K_g 表示被區間覆蓋的目標數目，則

$$\widehat{C}_g = \frac{K_g}{I_g}, \qquad \widehat{C}_g^{\text{service}} = \frac{K_g}{A_g}.$$

前者是「已發出區間的覆蓋率」，後者是「服務覆蓋率」：如果嘗試預測卻沒有產生區間，後者會把該次嘗試計作未覆蓋。兩種定義不能互換。一項服務若恰好在最難的情況下不作回答，只評估它成功回答的部分，便可能高估使用者實際得到的保障。換一個分母，不只是報表格式不同，而是改變了問題。

在本實驗的主要基準及三個候選方法中，每次嘗試都成功發出區間，所以兩種覆蓋率相同。這是已保存評估結果的特性，不是未來可用性的保證。區間寬度與 interval score 仍然只對已發出的區間有定義；若給沒有答案的預測一個人造的零寬度，反而會獎勵未能提供服務的情況。

但在這兩個分母之前，還有另一道資料範圍限制。主要評估與 ramp 標籤需要同時有已觀測的當前功率，以及已觀測的未來目標。若某個預測起點在發出預測前已被排除，它不會暗中留在服務覆蓋率的分母內。後面討論自然缺失資料時，這個區別尤其重要：即使某個評估範圍內的預測可用性是 100%，也不代表所有可能的停機或遙測失效情況都被涵蓋。

為甚麼要按站點與事件分開看？

資料來自 Chen 與 Xu 所介紹的中國國家電網公開競賽數據，於 2019–2020 年每 15 分鐘量度一次。本研究使用其中的太陽能站點檔案，不是一個模擬太陽能電站。資料的收集與原始背景可見數據論文。公開資料的價值在於讓研究問題可以建立在實際觀測之上，但「真實數據」不等於「任何部署情況都已受到驗證」。

CSGS1 被保留作方法開發。其餘七個候選站點，在比較方法結果之前，先按資料完整性規則篩選。最後留下 CSGS2、CSGS5、CSGS6、CSGS7 與 CSGS8，標稱容量依次為 130、110、35、30 及 30 MW。CSGS3 缺少必要的溫度欄位；CSGS4 的日間目標缺失率為 25.720%，高於預設的 20% 排除門檻。兩者都不是因為某個預測方法在那裏表現差而被刪去。

這個先後次序，保護了外部確認的意思。開發站點可以協助我們形成一個值得測試的方法，但不應再被當成全新的泛化證據。同樣地，資料篩選應回答「能否進行這個比較」，而不是挑選「哪些站點最容易產生我們想要的結論」。若先看結果才決定保留誰，後來的平均改善便很難解釋。

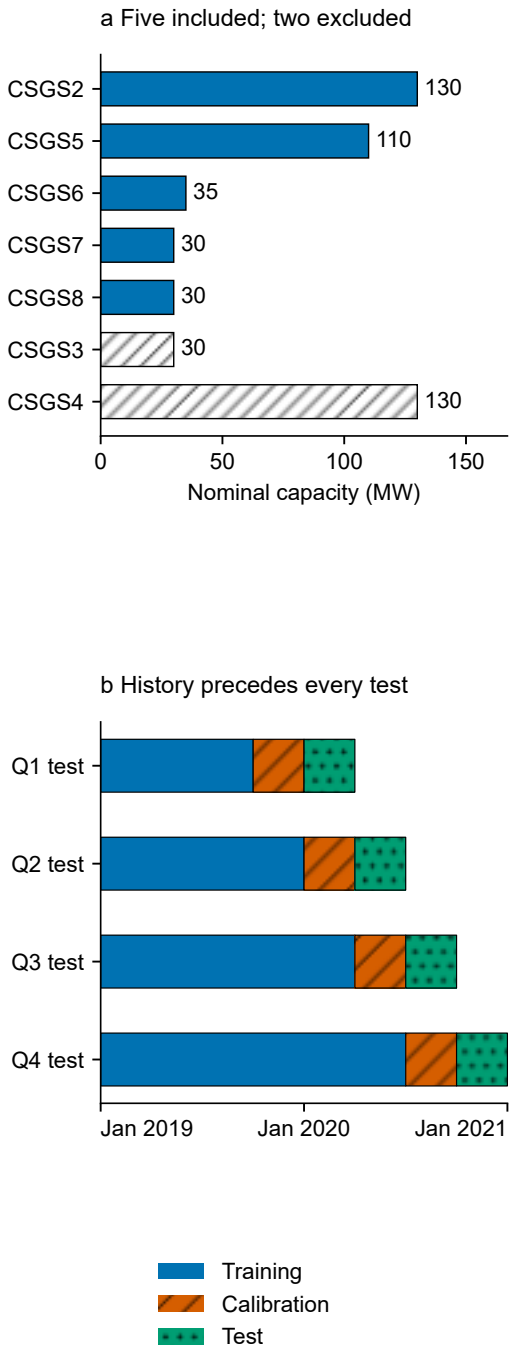


圖 2・五個確認站點的標稱容量介乎 30 至 130 MW。斜線柱表示排除的 CSGS3 及 CSGS4；CSGS1 只作開發，不列作確認站點。每段訓練資料之後，依次是校準季度及互不重疊的 2020 年測試季度；未來目標跨越資料分界的起點會被移除。時間軸呈現先後區段，不代表獨立重複，也不包含站點地理位置的推斷。

每個保留站點都測試 15 分鐘與 60 分鐘預測。四個測試季度涵蓋 2020 年：第一組訓練期在 2019 年 9 月結束，10–12 月用作校準，再以 2020 年 1–3 月作測試。之後每一折把歷史向前擴展，校準與測試各向前移一個季度。最後一組訓練期在 2020 年 6 月結束，第三季校準，第四季測試。

為甚麼不把時間戳隨機打亂？因為預測程序不應從它將要預測的未來時段學習。還有一個更隱蔽的問題：即使預測起點位於訓練期最後幾分鐘，它的未來目標也可能已落在下一個區段。按目標時間清除跨界起點，才真正阻止這種資料洩漏。只把輸入時間排序，並不足以保證未來反應沒有越過分界。

四個測試季度互不重疊，但不同資料折會重用較早的歷史。因此，它們不是每個站點各自進行四次獨立實驗。大量時間戳也不是大量獨立地理環境。統計上的重複單位是**站點**：40 個組合描述實驗設計，而五個站點才描述可用的外部重複證據。若把這兩個數字混為一談，便會把研究的廣度說得過大。

一般平均值的計算，先在每個站點內，對合資格的時間折—感測條件—事件群組給予相同權重，再對五個站點等權平均。這回答的是一個以站點為先的問題。如果把所有預測列直接合併，觀測較多的站點或群組便會得到更大影響力。兩者都可能有用途，但它們不是同一個統計量的兩種外觀。閱讀結果時，必須知道作者平均的是甚麼。

Ramp 是事後評估定義，不是預先知道的答案

以 $y_{s,t}$ 表示站點 s 在時間 t 的功率，C_s 表示其標稱容量。預測期以 15 分鐘步數表示，事件標籤定義為

$$r_{s,t,h} = \mathbf{1}\left\{ \frac{|y_{s,t+h} - y_{s,t}|}{C_s} \geq \tau_h \right\},$$
$$\tau_1 = 0.10, \quad \tau_4 = 0.20.$$

因此，ramp 指的是相對容量足夠大的功率絕對變化，急升與急跌都計算在內。容量正規化，讓不同大小站點可以用相同的相對尺度來定義變化，卻不表示這些站點的天氣、設備或動力機制都相同。站點代碼本身亦不提供足夠資訊，讓我們推斷其氣候或地理位置。

兩個門檻並不是等價的變化速率：15 分鐘內變動 10%，與 60 分鐘內變動 20%，選出的事件並不相同。它們是研究保留的事件定義，不是普遍物理臨界點、調度限制或正式操作標準。把門檻改掉，就是在用另一個事件問題檢查同一套預測，而不只是把橫軸改成另一種單位。

最重要的是，這個標籤需要未來功率。結果出現之後，我們可以知道某次預測是否遇上 ramp；發出區間的當下卻不知道。可部署的方法可以利用當前資訊估計 ramp 風險，但不能把真正的未來 ramp 標籤放進模型，再聲稱它只用了預測時可取得的資料。這條時間上的區分，會直接影響後面的「未來標籤診斷」如何解讀。

另一項近期全國尺度太陽能 ramp 研究，支持把快速變化視為值得單獨研究的預測問題；但它不會因此驗證我們這五個站點的結果，也不能替本研究建立地理代表性。兩者的規模與模型不同。這個互補背景可參考 Lanzilao 與 Meyer 的研究。

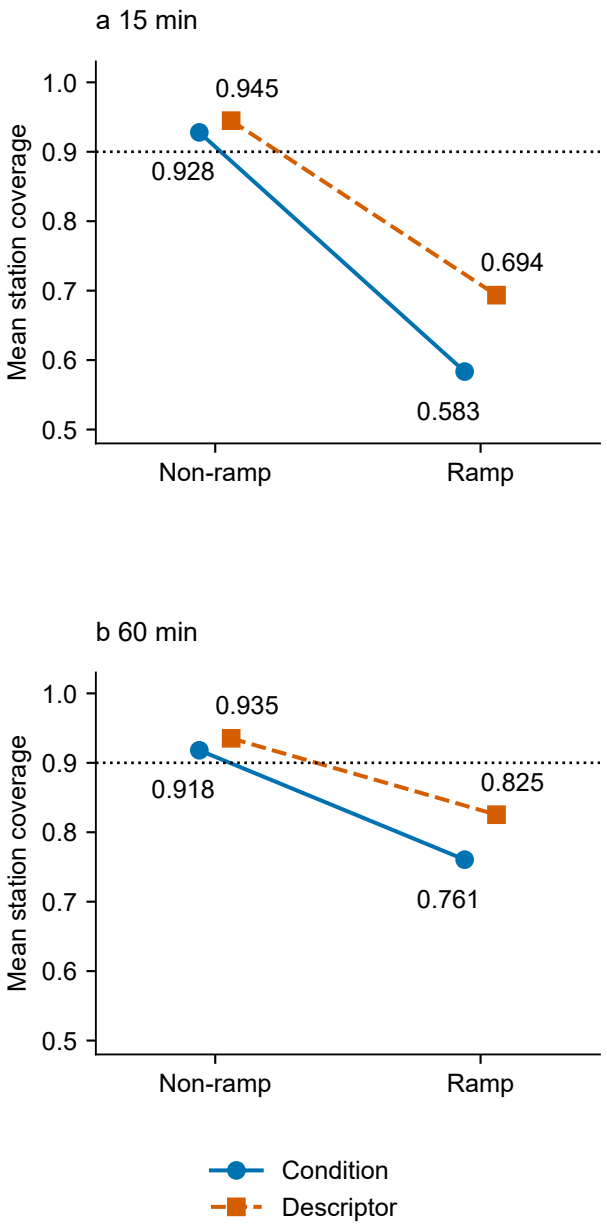


圖 3・分開普通變化與 ramp 的平均站點覆蓋率。15 分鐘下，Condition／Descriptor 的非 ramp 覆蓋率為 0.928／0.945，ramp 則為 0.583／0.694；60 分鐘下，相應數值為 0.918／0.935，以及 0.761／0.825。每種方法、每個預測期、每個事件分層都有 100 個合資格群組，即五站、四折及五種感測條件。先在站內平均，再在五站間平均；點不是信賴區間。點線表示標稱 0.90 覆蓋率。

這幅圖說明了為甚麼只報一個平均數並不足夠。校準令兩類群組都改善，但 ramp 覆蓋率仍有明顯短缺。它亦解釋了為甚麼最差群組可以遠差於平均 ramp 群組：後者把不同站點、季度與感測條件混合平均，前者則刻意追問，在哪個有足夠觀測的情境中，這種平均最不能令人放心。

校準如何改變預測區間？

主要比較固定了底層預測器。在每個站點—時間折—預測期的運算中，Condition CQR、Descriptor CQR、Risk-Mondrian、Rolling CQR，以及未來標籤診斷，共用一個經感測退化資料增強的 Extra-Trees 模型。因此，這幾種方法之間的變化，主要反映在同一預測基礎上如何進行校準，而不是每個方法各配一個不同預測器的競賽。

初始區間由森林中各棵樹的點預測之經驗分位數建立。這並不是把葉節點中所有反應值收集起來，再取反應分位數。這個區別很重要：多棵擬合樹之間的意見相近，不自動代表它們已準確描述未來結果的不確定性。即使模型集成看起來很一致，仍可能共同低估某種事件。校準的作用，就是利用已觀測的誤差調整原來的區間。

Romano、Patterson 與 Candès 提出的 Conformalized Quantile Regression提供了一般出發點。本研究採用只擴張、不收縮的分數：

$$a_i = \max\{\hat{q}_\ell(x_i) - y_i, y_i - \hat{q}_u(x_i), 0\}.$$

如果觀測已在初始區間內，分數便是零；如果低於下界或高於上界，分數就是要把區間向外擴張多少，才足以把該觀測納入。公式中的零不是可有可無的寫法，而是令這個版本只會擴張。它不會利用負修正，把本來已經偏寬的初始區間收窄。這亦是閱讀方法名稱時必須留意的地方：同屬 CQR，實際分數定義仍然會影響行為。

給定一個非負修正量 $q(x)$，最終端點為

$$L(x) = \max\{0, \hat{q}_\ell(x) - q(x)\},$$
$$U(x) = \min\{C_s, \hat{q}_u(x) + q(x)\}.$$

把端點限制在零與容量之間，是保留模型所用的物理輸出範圍；它不會把一個經驗估計的修正量，變成普遍可靠性保證。如何選修正量、它使用哪些資訊、校準期是否足以代表測試期，仍然是必須回答的問題。下面四種方法，正是在這個修正步驟採取不同做法。

四種決定擴張幅度的方法

Condition CQR 按已知的感測條件分組校準。天氣輸入缺失的預測，不必使用與完整輸入相同的修正量。這個基準承認缺失資訊會改變誤差，但同一感測條件內仍可能包括很不同的事件風險；一個條件級修正值，仍然是在這些情境之間作某種折衷。

Risk-Mondrian 再加入四個預測時風險分層。另一個 Extra-Trees 分類器，利用訓練資料與可用特徵估計 ramp 風險。校準分數按感測條件及風險箱分組。為免小群組的估計過於不穩，方法把該箱修正量與條件級修正量混合；有 n 個校準觀測時，該箱的權重為 $n/(n+100)$。空箱則退回條件級修正。這是在群組之間分享資訊，而不是把稀疏群組的分位數當成同樣可信。

Descriptor CQR 直接建立分數模型。LightGBM 分位數模型使用 15 個描述量，包括估計風險、按容量正規化的初始寬度及中位數、三類特徵缺失比例、已觀測背景比例、時刻的正弦與餘弦、轉換風險，以及五個感測條件指標。它是「分數模型加按時間排列的殘差校準」，**不是近鄰校準**。模型要從預測情境的描述，估計適合的擴張程度，而不是先量距離、再找鄰近案例。

最早 60% 的獨立校準時間點用來擬合分數模型；較後 40% 用來計算另一層殘差修正。若模型估計的分數分位數是 $\hat{q}(x)$，最後修正形式為

$$
\begin{aligned}
q(x) &= \max\{\hat{q}(x) + \kappa, 0\}, \\
\kappa &= \max\{0, Q^{\text{residual}}_{1-\alpha}\}.
\end{aligned}
$$

這裏 $\alpha = 0.10$。殘差分位數使用有限樣本次序 $\lceil (n+1)(1-\alpha) \rceil$，並限制在可用的 1 至 n 範圍。分割按照獨立時間點進行，避免同一時間的多種感測條件副本跨越兩部分。先擬合分數關係，再用較後資料修正殘差，目的就是不把同一批擬合誤差同時當作獨立的校準檢驗。這種安排保留時間順序，但不是本研究新建立的條件覆蓋定理。

Rolling CQR 則使用每種條件最近 500 個已釋放分數，並要求至少有 100 個。「已釋放」是關鍵：一個 60 分鐘預測的誤差，不會在發出預測後立即知道，必須等到相應目標真的出現。若提早把它加入滾動校準，就等於把未來資訊偷偷交給了模型。對時間序列而言，方法的更新時間本身也是科學假設的一部分。

這些機制以不同方式處理異質性與時間變化，但沒有任何一種可以省略困難群組評估。序列預測共形推斷研究殘差之間的時間依賴；自適應共形預測則研究隨時間調整的方法。這些工作的理論結論各有指定方法與假設，不能因為名稱相關，就自動移植到本研究的實證流程。

感測壓力測試究竟移除了甚麼？

研究設五種情況：完整輸入、移除輻照特徵、移除天氣特徵、移除近期功率特徵，以及合併移除。三個特徵家族分別包含 9、9 與 13 個特徵；合併條件移除其聯集，共 31 個。被預測的目標仍然是已觀測值，沒有進行插值。

這是一種受控比較：在預測起點限制某些資訊，觀察不同校準方法如何回應。它不是完整的儀器老化模型，亦沒有模擬停機持續時間、通訊恢復、突發雜訊或量度漂移。底層預測器也接觸過退化訓練例子，所以不能把它說成對一種完全未知故障的盲測。這些實驗最直接的價值，是讓方法在相同目標及清楚定義的資訊限制下接受比較。

改善是一個比較，可靠性是一個要求

對每個合資格群組，我們相對於 90% 目標定義欠覆蓋，再在每個站點與預測期內取最大短缺：

$$
\begin{aligned}
u_g &= \max\{0, 0.90 - \widehat{C}_g\}, \\
W_{s,h}^{(m)} &= \max_{g \in \mathcal{G}_{s,h}} u_g .
\end{aligned}
$$

群組至少需要 80 個已發出區間。這條規則排除非常小的樣本格，但 80 並不是精度保證。相鄰預測可能有依賴，而最大值亦是在多個群組中挑選出來。最差群組是值得檢查的地方，不代表它的樣本估計已成為沒有雜訊的母體常數。這也是我們同時保留群組樣本數、站點數與具體條件的原因。

研究刻意採用一個相對寬鬆的絕對檢查：

$$
W_{s,h}^{(m)} \le 0.10 \quad \text{at every station.}
$$

由於目標是 0.90，這條要求容許合資格群組的覆蓋率低至 0.80。它是研究用的檢查底線，不是說電網操作只需 80% 就足夠；它亦不是顯著性檢定或業界標準。即使通過，仍有操作層面的驗證未完成。因此，未通過這條已經寬鬆的底線，是一個不能被平均改善掩蓋的結果。

相對比較則問另一組問題：平均站點改善是否至少 0.05？是否至少 60% 的站點有正改善？以站點重抽樣計得的「候選減基準最差欠覆蓋」上界，是否低於零？完整輸入條件下的 proper score 比值，是否不超過 1.10？平均配對改善定義為

$$\overline{\Delta}_h = \frac{1}{5}\sum_{s} \left(W_{s,h}^{\mathrm{Condition}} - W_{s,h}^{\mathrm{candidate}} \right).$$

正值代表候選方法較好。配對保留站點身份：某站點有大幅改善，不應被當成另一站點也受益的證據；每一次比較都由該站自己的基準出發。同時，若某個候選只靠大幅拉寬所有區間來獲得覆蓋改善，完整輸入條件下的評分限制會提供另一個檢查角度。

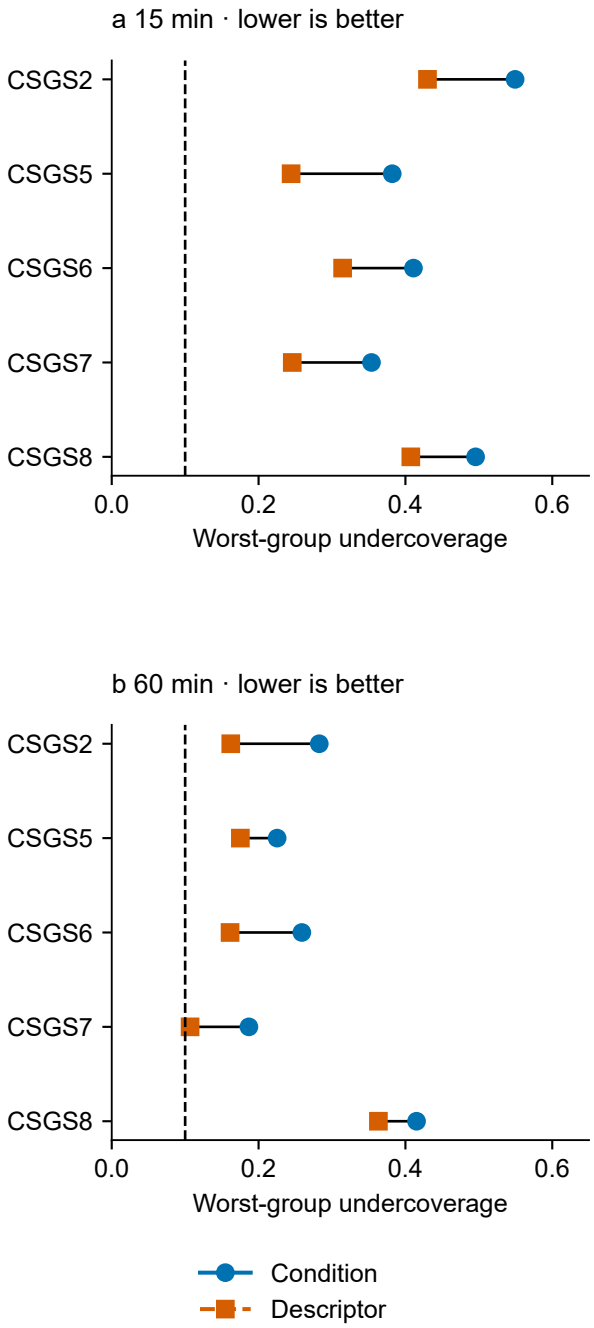


圖 4・每個預測期的五組站點配對。藍色圓點表示 Condition CQR，橙色方點表示 Descriptor CQR；連線連接同一站點，不是信賴區間。每組都改善，但每個 Descriptor 結果仍在 0.10 欠覆蓋容差虛線右側。不同方法的最差群組可以不同，所以連線比較的是站點最差端點，不是同一個已選時間戳群組。

Descriptor CQR 在兩個預測期都符合相對比較準則。Risk-Mondrian 只在 15 分鐘符合；它在 60 分鐘的平均改善 0.040，低於要求的 0.05。Rolling CQR 在兩個預測期都未符合比較準則。**所有可部署候選，都沒有符合絕對可靠性準則。**

預測期（分鐘）	候選方法	平均改善	相對比較準則	絕對可靠性準則
15	Descriptor CQR	0.110	符合	不符合

預測期（分鐘）	候選方法	平均改善	相對比較準則	絕對可靠性準則
15	Risk-Mondrian	0.079	符合	不符合
15	Rolling CQR	-0.002	不符合	不符合
60	Descriptor CQR	0.080	符合	不符合
60	Risk-Mondrian	0.040	不符合	不符合
60	Rolling CQR	0.022	不符合	不符合

表中亦保留了有用的負面證據。較近期的校準視窗，不自動等於對下一次困難事件有更好的描述。Rolling 在 15 分鐘的平均變化略為不利，不是一個被省略的平手；60 分鐘雖然有正改善，卻仍不足以符合要求。這些是指定程序的觀測結果，不代表所有可能的滾動校準方法都注定失敗。

五站設計亦限制了不確定性陳述的力度。站點級 bootstrap 描述已觀測站點之間的變異，不會製造額外站點。即使摘要區間支持平均改善，仍有必要展示每一組配對。共同資料來源與有限站點數，使我們不能進一步聲稱方法已在廣泛地理或氣候條件下可靠。結果可以支持下一輪研究，但不能靠重新命名重複單位來擴大結論。

更寬的區間，不是免費的改善

假如每次都給出涵蓋所有合理功率值的區間，覆蓋率通常會很好看，卻幾乎沒有區分能力。因此，只看覆蓋率，容易獎勵一個過於簡單的反應：把每條陰影帶都畫得更闊。本研究同時報告區間寬度，以及兼顧寬度與漏失的 proper interval score。

當 $\alpha = 0.10$，評分為

$$
\begin{aligned}
S_\alpha(L, U; y) = (U - L) \\
&+ \frac{2}{\alpha}(L - y)\mathbf{1}\{y < L\} \\
&+ \frac{2}{\alpha}(y - U)\mathbf{1}\{y > U\}.
\end{aligned}
$$

第一項為寬度付出代價；另外兩項分別懲罰低於下界或高於上界的距離。只差少許就進入區間，與偏離很遠，得到的懲罰並不一樣。把寬度及評分都除以站點容量，可以在不同規模站點之間使用可比較的報告尺度。評分越低越好，並不是越高越有信心。

這裏的係數 $2/\alpha$ 等於 20。舉一個假想數值例子：正規化寬度為 0.20，而真值高於上界 0.05，則評分為 1.20。若把上界擴張到能包含真值，雖然增加了寬度代價，卻消除了一個更大的漏失懲罰。但放到很多觀測上，擴張亦會令原本已覆蓋的案例付出額外寬度。因此，整體得失不能只靠這一個例子判斷，必須從實際結果計算。

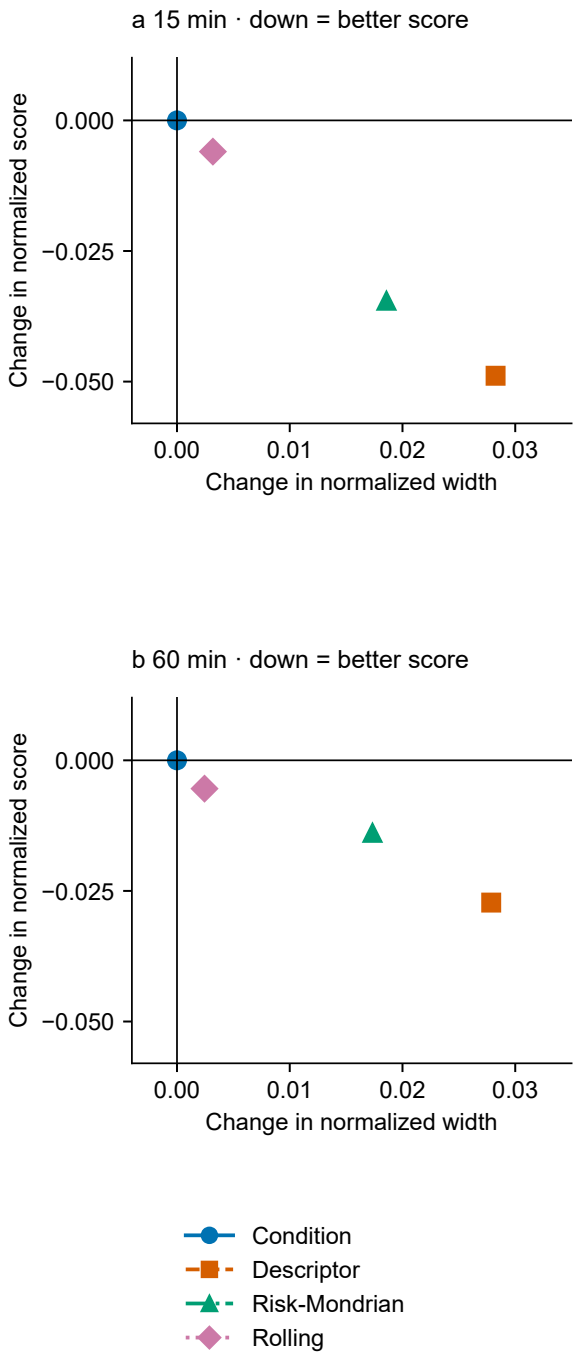


圖 5・15 與 60 分鐘下，相對 Condition CQR 的寬度—評分取捨。先對每站合資格群組等權平均，再對五站等權平均。向右表示區間更寬，向下表示正規化 proper interval score 更好。Descriptor 在兩個預測期的寬度均增加 0.028，評分分別改變 -0.049 與 -0.027。四個主要方法在這些評估中都成功發出每個區間。點代表已保存的整體估計，並無暗示不確定性帶。

Descriptor 的平均正規化寬度在兩個預測期都增加 0.028，而正規化 proper score 分別下降 0.049 及 0.027。這表示更寬的區間，在本次比較中確實改善了兼顧覆蓋與集中程度的評估，而不只是單純把覆蓋率推高、沒有其他利益。

但這個結論不能抹去取捨變差的群組。15 分鐘下，非 ramp 覆蓋率增加 0.017，寬度增加 0.012，評分卻惡化 0.001；ramp 則分別改變 +0.110 覆蓋、+0.045 寬度及 -0.099 評分。較大的 ramp 改善，解釋了為甚麼整體可以變好，同時普通情況卻付出少量效率代價。「平均更好」與「每一部分都更好」，依然是兩句不同的說話。

60 分鐘下，非 ramp 的變化是 +0.017 覆蓋、+0.015 寬度及 -0.004 評分；ramp 的相應變化是 +0.065、+0.040 及 -0.051。這些是相關群組的平均值，不是前面展示的最差群組端點。不能把分層平均評分與站點最大短缺直接相減，再把所得數字解釋成一個新的性能指標。

既有的太陽能共形預測研究為區間校準提供了背景。本研究補充的是一個較窄、但重要的提醒：整體區間評分改善，不會自動修復最弱的條件覆蓋率。至於區間能否協助真實控制決策，還取決於決策規則、不同方向錯誤的後果，以及操作人員實際可以採取的行動。本研究沒有量度這些調度結果，因此不會把評分改善直接換算成電網收益或安全保證。

為甚麼未來標籤不是性能上限？

一個很自然的疑問是：如果校準器預先知道 ramp 將會發生，情況會怎樣？研究加入了一個使用真實未來 ramp 標籤的參考方法。這是刻意使用預測時不可能取得的資訊，所以它是一項診斷比較，不是可部署的候選。

我們可能很想把它叫作「完美資訊上限」，再把剩餘差距拆成資訊不足與校準不足兩部分。然而，這種解讀並沒有得到支持。知道標籤，會改變哪些校準觀測被分到同一群組，卻不保證從有限群組估計出來的修正量，一定優於另一種方法。有限校準樣本、不同分組，以及最差群組這個目標本身，都可能令比較更複雜。

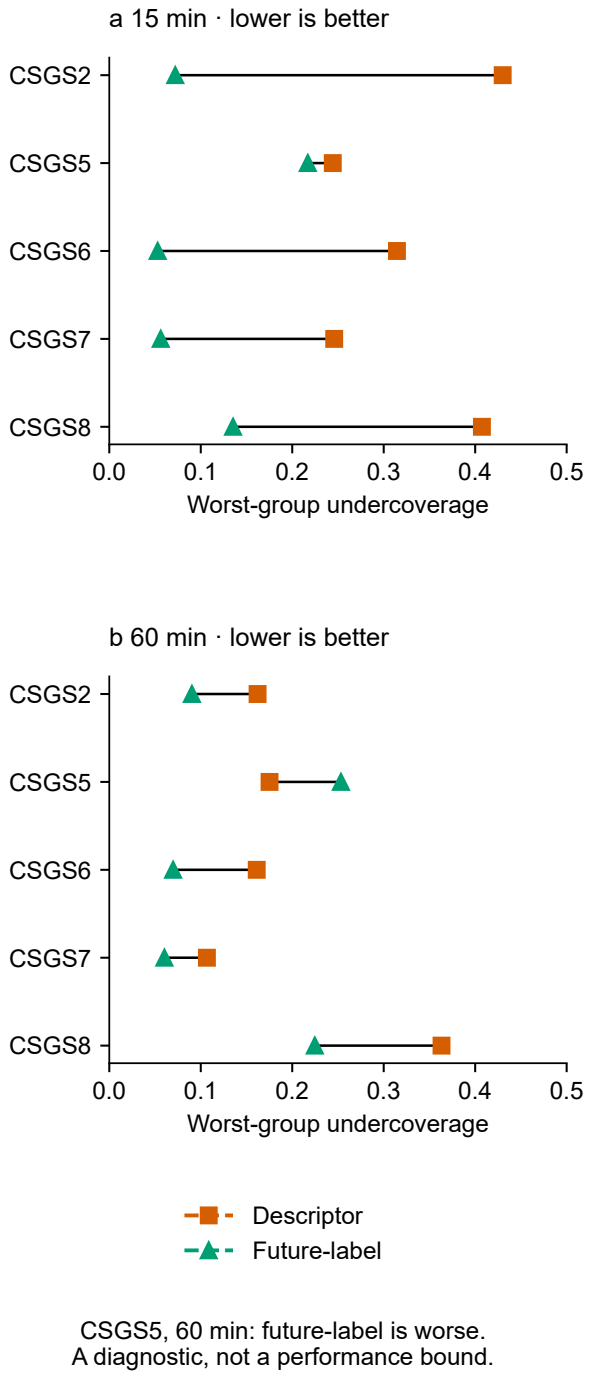


圖 6・每個預測期的五站配對，比較 Descriptor CQR 與使用真實未來 ramp 標籤的參考方法。該標籤在預測時不可取得。CSGS5 在 60 分鐘下，Descriptor 的最差群組欠覆蓋為 0.175，未來標籤參考卻為 0.253，圖中保留這個逆轉。連線只是描述性比較，不是可相加的成分、因果效果、誤差棒或保證性能上界。

CSGS5、60 分鐘是關鍵反例：未來標籤參考的最差群組欠覆蓋反而較大，達 0.253，而 Descriptor 是 0.175。擁有額外資訊的特定方法，不一定在每個站點與每個評估準則下，都是更好的有限樣本程序。這不表示未來資訊本身有害，而是說這個參考方法，並不是所有可以利用該資訊的方法之中的最優解。

Descriptor 減去參考方法的欠覆蓋差距，中位數在 15 分鐘為 0.262，60 分鐘為 0.072。這些摘要可以協助提出哪些預測時描述量值得研究，但不能識別因果貢獻。我們沒有在其他機制全部固定的條件下，單獨干預大氣資訊；亦沒有建立任何可把總誤差拆成幾個成因的分解定理。

這也是圖像採用配對點、而不是堆疊柱的原因。堆疊柱容易暗示總短缺可以分成幾個非負的解釋部分，彷彿每部分都有清楚來源。但這裏連差距的符號也可能逆轉。較誠實的下一個科學問題，是更好的預測時風險資訊，能否在新的評估中減少困難群組誤差；而不是聲稱目前已經因果地分配好，每一部分誤差究竟來自甚麼。

結論會不會依賴事件門檻？

不重新擬合模型，也可以用不同 ramp 定義來評估已保存預測。15 分鐘門檻取容量的 7.5%、10% 及 15%；60 分鐘則取 15%、20% 及 25%。區間預測本身保持不變，改變的只是哪些事件被歸入 ramp。

這是一項**評估標籤敏感度分析**。訓練權重、風險分類器標籤、校準器，以及未來標籤參考，仍使用原來的標稱定義。不能把這些曲線說成每一個門檻都各自重新最佳化的完整預測系統。如果另做一項在不同門檻重新訓練的研究，結果可以不同；那會是新的實驗，不是本圖已回答的問題。

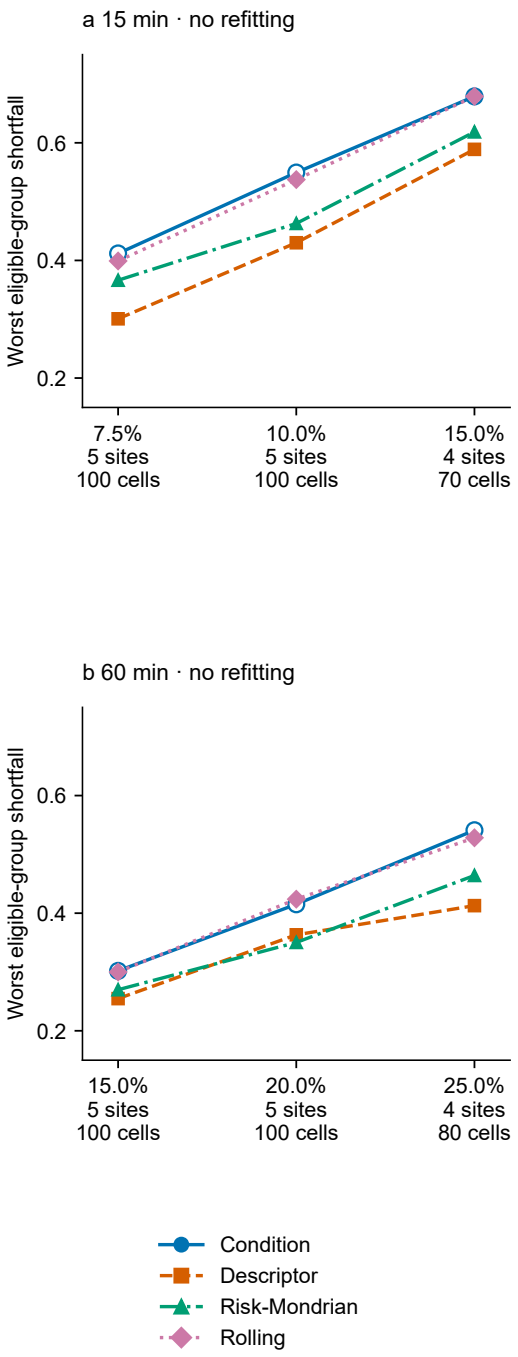


圖 7・固定預測下，不同事件標籤的合資格群組最差欠覆蓋。刻度文字列出有足夠 ramp 樣本的站點數，以及至少 80 個已發出區間的時間折—感測條件 ramp 群組數。15 分鐘的群組數依次是 100、100、70；60 分鐘是 100、100、80。最高門檻下，CSGS8 沒有合資格 ramp 群組，所以只餘四個 ramp 可評估站點。部分 Condition 與 Rolling 點有意重合；曲線只連接已評估門檻，不是擬合出的連續定律。

15 分鐘的 ramp 起點數由 12,928 減少至 8,269，再減少至 3,946；60 分鐘則由 24,267 減少至 13,718，再減少至 6,903。這些是預測起點數，不是跨五種感測條件複製後的五倍列數。更嚴格門檻選出更少、幅度更大的變化，因此事件難度與樣本支持同時在改變，不能假設只有其中一項改變。

最高的 15 分鐘門檻下，CSGS2 只保留 10 個合資格 ramp 群組，另外三站各有 20 個，CSGS8 一個也沒有，總數是 70。最高的 60 分鐘門檻下，四站各有 20 個，CSGS8 再次沒有，總數是 80。支持數量中的零，表示沒有符合規則的群組，不表示已觀測到零錯誤率。如果把它畫成一條貼着零失敗線的柱，就會把資料不足錯寫成好消息。

Descriptor 的最差合資格群組短缺，在三個 15 分鐘門檻下依次為 0.301、0.430、0.589；60 分鐘則為 0.255、0.363、0.413。結果支持我們關注更困難事件下的可靠性，但合資格群組的範圍亦在改變，所以不能簡單說成同一個完全不變的五站 ramp 面板，沿着門檻逐步變差。

檢查容差亦可以在不改任何預測下改變。欠覆蓋容差 0.05、0.10 與 0.15，分別對應 85%、80% 與 75% 的覆蓋底線。即使採用最寬鬆的一條，也只有 Descriptor 在 60 分鐘的一個站點達標；沒有方法符合所有站點都達標的要求。移動報告上的線，不會改善預測本身；敏感度分析亦不應變成尋找一條能讓失望結果消失的線。

自然缺失資料到底能告訴我們甚麼？

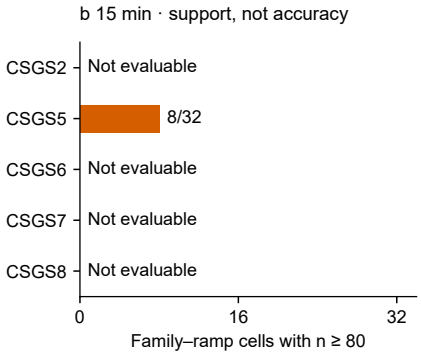
人工移除特徵，提供了一種受控比較；自然缺失則提出另一個問題：歷史紀錄是否真的包含足夠相關案例，讓我們檢查量度本來就缺失時發生了甚麼？兩種分析有關聯，但不能只因為都叫「缺失」，便視為同一種驗證。

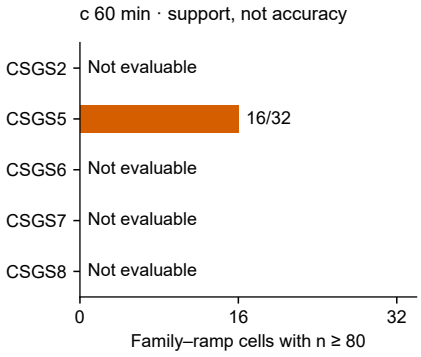
先看資料範圍。15 分鐘下，有 110,425 個日間測試起點具有已觀測的未來目標；其中 382 個缺少當前功率而被排除，留下 110,043 個模型可評估起點。60 分鐘的相應數字是 110,302、1,348 及 108,954。這些排除發生在本分析所用的預測與 ramp 標籤之前。因此，完整的當前功率遙測中斷，並沒有受到本研究評估。

再看條件樣本支持。自然缺失分析從四個主要方法的完整條件預測中，選出相關特徵家族本來就有缺失的案例。資料格式中原本不存在的可選通道，不被當作持續故障的感測器。五站、四折、兩個預測期、四個特徵家族、兩種事件分層，共組成 320 個家族—ramp 群組；只有 24 個達到至少 80 個觀測的要求，而且全部來自 CSGS5。

a Observed targets are not enough

Horizon	Target observed	Current missing	Can evaluate
15 min	110,425	382	110,043
60 min	110,302	1,348	108,954





24 / 320 cells qualify, all at CSGS5.
Overlapping selections are not replicates.

圖 8・自然缺失分析的適用範圍。上表分開已觀測未來目標、當前功率缺失排除，以及模型可評估起點。下方展示每站每個預測期 32 個可能家族—ramp 群組中的合資格數：15 分鐘有 8 個，60 分鐘有 16 個，全部在 CSGS5。其餘站點標示為不可評估，而非沒有錯誤。24／320 包含互有重疊的特徵家族選取；合併計算性能時，相同時間戳集合只計一次。

「支持數量」與「性能」的差別非常重要。八個合資格群組的柱不是準確率分數；兩個家族標籤若選中完全相同的時間戳，也不是兩次獨立重複。自然缺失摘要會先去除近期功率與合併家族中相同的選取集合，再合併性能。否則，看起來更豐富的分層，實際上只是同一批觀測被重複展示。

被選中的結果同時有收益與代價。15 分鐘非 ramp 子集有 4,189 個觀測：Descriptor 減去 Condition 的變化，依次是覆蓋 -0.002、欠覆蓋 +0.000、正規化寬度 +0.003，以及正規化評分 +0.001。60 分鐘的 3,767 個非 ramp 觀測，依次得到 +0.020、+0.000、+0.016 及 +0.003。也就是說，在這些選定的非 ramp 子集中，區間更寬、甚至覆蓋更高，也未必換來更好的評分。

在被選中的 614 個 60 分鐘 ramp 觀測中，相應變化是覆蓋 +0.033、欠覆蓋 -0.022、寬度 +0.028，以及評分 -0.018。覆蓋增益與欠覆蓋減幅不同，是因為欠覆蓋在零截斷：合併覆蓋一旦越過 0.90，繼續增加覆蓋，不會再減少已經為零的短缺。先合併覆蓋再截斷，也不同於先把每個群組截斷、再平均那些短缺；這裏報告的自然缺失比較採用前者的合併量。

這不是純粹的算術細節。若讀者想檢查數字，卻把兩個不同聚合次序混用，就會以為研究前後不一致；若作者沒有說明次序，則可能在不知不覺間改變了所回答的問題。最差群組、站點等權平均與選定案例的合併覆蓋，各自都有不同作用，不應在同一段結論中互相替代。

這些結果是一項運算後的描述性敏感度分析，不是跨五個站點的新確認。缺失值下的共形預測研究有助理解為甚麼缺失模式值得明確檢查，但它不會讓這個被選中的 CSGS5 子集，自動代表所有缺失機制或真實停機。資料中的自然缺失，與實際操作中最令人擔心的完全無訊號情境，可能有不同的選取條件。

因此，下一步不完全是一個模型複雜度問題，也是一個量度問題。在提出更複雜校準器之前，應先問：哪些目前被排除的情況，能否被誠實地觀測和評估？未來研究可能需要在遙測中斷期間獨立保存真實目標，並設計不依賴當前功率的預測程序。這是下一項研究的設計方向，不是本次資料已提供的證據。

下一步應該測試甚麼？

有三個問題自然地接着出現。第一，預測時可取得的描述量，能否更有效區分將要發生的困難事件，而不使用真正的未來標籤？有說服力的測試，應保留按時間擬合，並評估新的站點級結果，而不是在看過同一批最差群組之後，再挑選最能解釋它們的描述量。

第二，能否改善普通情況下付出過多寬度代價的部分？好的候選應保留 ramp 覆蓋收益，同時避免在其他情境不必要地擴張。這需要一起報告覆蓋、寬度與 proper score，而不是當某個結果不方便時，就換另一個數字做標題。指標之間存在取捨，本身就是需要研究的現象，不應被單一總排名蓋過。

第三，哪一種可靠性要求才真正對應某個決策？本研究分開檢查兩個預測期，沒有檢查整條未來軌跡的同時覆蓋。ConForME說明了多預測期不確定性為甚麼是另一個問題。如果決策依賴一連串功率值、儲能限制或不對稱備轉成本，就需要圍繞該決策設計評估。兩個個別預測期的檢查，不能默默升格成整段軌跡的保證。

三個問題都需要新的證據。更多站點能加強外部重複；更完整的停機紀錄能擴大可評估情況；以決策為中心的實驗能測試操作價值。這些工作都不能被同一個有限資料環境中更多的時間戳取代，彷彿它們就是新的獨立世界。把下一個問題說得具體，比把目前結果說得更大，更有助於研究向前走。

結論

最令人鼓舞的結果，同時也是我們不應過度自信的原因。Descriptor CQR 在每個確認站點，都改善了最差群組端點；較寬的區間亦換來更好的整體 proper score。在本研究所評估的比較範圍內，這個改善是存在的。

然而，最困難群組的覆蓋率仍只有 0.470 與 0.537，標稱目標卻是 0.90。沒有可部署候選通過那條已經刻意寬鬆的所有站點可靠性檢查。因此，研究支持繼續改善條件校準，不支持聲稱太陽能 ramp 與感測退化下的不確定性問題已被解決。

下一次看見預測旁邊令人放心的陰影帶時，值得問的不只是「這個方法有沒有擊敗基準」。更有用的問題是：在哪些條件下可靠？涵蓋了哪些預測嘗試？在哪些站點？付出了多大區間寬度？又是為哪一種決策服務？當這些問題變得更容易回答，不確定性估計才真正變得更有用。

研究與作者紀錄

本文解說的論文是 *When Solar Power Changes Fast: A Multi-Site Audit of Prediction-Interval Reliability under Ramp Events and Sensor Degradation*。按正式作者次序，作者為 **Hong U Lo、Zibo Gao、Peng Chi Lam、Sok Kin Cheng**；所屬機構為 St. Joseph Diocesan College (The Fifth School), Macao SAR, China。Sok Kin Cheng 為通訊作者及學生研究指導老師。

研究於 **2026 年 9 月 3 日，由 ADMA 2026 Research Track 接納為 Short Paper**，並於 **2026 年 9 月 9 日完成 camera-ready 提交**。會議預定於 2026 年 11 月 13–15 日在香港舉行。目前記錄的是接納與提交兩個里程碑；本頁不聲稱已完成報告、已有正式論文集條目、已獲索引，或已有論文 DOI。

數值解說依據已提交的八頁署名正式稿及其公開研究版本。本文圖像由已保存結果重新繪製，不是重新訓練模型所得的新實驗。專案頁提供精簡介紹；研究指導紀錄提供教育背景。

參考文獻

1. Chen, Y., and Xu, J. (2022). Solar and wind power data from the Chinese State Grid Renewable Energy Generation Forecasting Competition. *Scientific Data*, 9, 577.
2. Lanzilao, L., and Meyer, A. (2026). Characterization and forecasting of national-scale solar power ramp events. arXiv 預印本。
3. Galvão Lopes, A., Goubault, E., Putot, S., and Pautet, L. (2024). ConForME: Multi-horizon conditional conformal time series forecasting. *PMLR*, 230, 345–365.
4. Renkema, Y., Visser, L., and AlSkaif, T. (2024). Enhancing the reliability of probabilistic PV power forecasts using conformal prediction. *Solar Energy Advances*, 4, 100059.
5. Romano, Y., Patterson, E., and Candès, E. (2019). Conformalized Quantile Regression. *Advances in Neural Information Processing Systems*, 32.

6. Xu, C., and Xie, Y. (2023). Sequential Predictive Conformal Inference for Time Series. *PMLR*, 202, 38707–38727.
7. Zaffran, M., Dieuleveut, A., Josse, J., and Romano, Y. (2023). Conformal Prediction with Missing Values. *PMLR*, 202, 40578–40604.
8. Zaffran, M., Féron, O., Goude, Y., Josse, J., and Dieuleveut, A. (2022). Adaptive Conformal Predictions for Time Series. *PMLR*, 162, 25834–25866.